

سوال اول قسمت اول: چون در اکثر مواقع وادون ماتریس X وجود ندارد و در این موقع از متب وادون ماتریس X^+ جای بیان دقیق تر از وادون X - پس استفاده می کنیم. اما ماتریس X را به نحوی X^+ ماتریس V^T U به نحوی می کنیم چاروش SVD سپس متب وادون را از رابطه $X = V \Sigma U^T$ بدست می آوریم:

در هر فرجه و تمام عناصر آن باید مقدار آستانه مقایسه می کنیم اگر $T_{ij} > \alpha$ آنگاه $T_{ij} = 0$ تا آن قرار می گیریم. در آخر X^+ را حاصل می کنیم و در ماتریس بدست آمده را مقایسه می کنیم و کم را بدست می آوریم و به جای X قرار می دهیم و در نهایت $N = X^+$ می شود. نکته این است که متب وادون همیشه تعریف نشده است.

سوال اول قسمت دوم: ابتدا ما باید تابع تلفیق زنده را بدست آوریم که با این داده ما $P_i +$ شوند، ما با استفاده از یک Sk این تابع را به صورت N بدست آوریم.

$$y = 0.97511283n + 12.752710154723119$$

متب $Durbin-Watson$ را می نویسیم:

$$eT = (y - \hat{y}) \quad d = \frac{\sum_{t=1}^T (eT_t - eT_{t-1})^2}{\sum_{t=1}^T eT_t^2}$$

$\alpha = 0.05$ و $\sum_{t=1}^T eT_t^2 = 17824.55449524$

$$Q = \frac{(eT_1 - eT_0)^2 + (eT_2 - eT_1)^2 + \dots + (eT_{10} - eT_9)^2}{\sum_{t=1}^T eT_t^2}$$

$$= \frac{20.27230709}{17824.55449524} = 0.0011335 \approx 0$$

- $eT_1 = 40.4211452$
- $eT_2 = 22.01009113$
- $eT_3 = 44.32452221$
- $eT_4 = 24.27278225$
- $eT_5 = 48.1209559$
- $eT_6 = 70.01197219$
- $eT_7 = 72.424984$
- $eT_8 = 74.7925739$
- $eT_9 = 75.1292111$
- $eT_{10} = 72.12219925$


$d \approx 2(1 - \hat{\rho}) = 2(1 - \frac{0.0011335}{1}) \approx 1.9978669$

$d > d_U$? Do NOT REJECT $H_0 \Rightarrow$ not first order serial correlation

$d > d_L$? INCONCLUSIVE

$d < d_L$? REJECT H_0


Binary step : $f(n) = 1 \quad n \geq 0 \rightarrow \text{Threshold}$
 $f(n) = 0 \quad n < 0$



$f'(n)$: $0 \quad n > 0$
 $\delta(n) \quad n \geq 0$
 $0 \quad n < 0$

- ① ✓
- ② ✗
- ③ ✓
- ④ ✓

Sigmoid : $G(n) = \frac{1}{1+e^{-n}}$
 $G'(n) = G(n)(1-G(n))$




مشتق تابع سیگموئید = $\delta(n)$ برای $n \geq 0$

- ② مقادیر مثبت
- ③ مقادیر منفی کم
- ④ مشتق مثبت است

- Sigmoid
- ① ✓
 - ② ✗
 - ③ ✗
 - ④ ✓

Tanh : $T(n) = \frac{e^n - e^{-n}}{e^n + e^{-n}}$


Tanh'(n) : $1 - T(n)^2$



- ① ✓
- ② ✓
- ③ ✗
- ④ ✓

ReLU : $f(n) = \max(0, x)$


$f'(n) = \begin{cases} 1 & n > 0 \\ 0 & n \leq 0 \end{cases}$



- ① ✓
- ② ✗
- ③ ✓
- ④ ✓

Leaky ReLU : $f(n) = \begin{cases} n & n > 0 \\ \alpha n & n \leq 0 \end{cases}$

$f'(n) = \begin{cases} 1 & n > 0 \\ \alpha & n \leq 0 \end{cases}$




- ① ✗

$$f(x) = \text{swish}(x) = x \sigma(Bx) \quad , B \text{ is constant}$$


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$f(m) = \text{swish}(m)$$



$$f'(x) = \text{swish}'(x) = B f(Bx) + \sigma(Bx) (1 - B f(Bx))$$

$$f'(m) = \text{swish}'(m)$$



این تابع میخوره و در تمام نقاط هاشون پذیراست.

بر خلاف تابع ReLU از مشکل فرودن معیار در حال برگردن برون

در بعضی از مقایسات هالو مثل CIFAR و ImageNet از ReLU بهتر است

به عنوان یک تابع فعال سازی عین اشباع از مشکل اعتبار یا ناپدید شدن گرادینت در برون برون

به علاوه یکی از تابع ReLU معوقه حل می کند اما در مقایسه با مقیم توابع فعال سازی هالو مشابه دارد

تجربا توجه به پارامتر B که تاثیر گذر است می توان گفت مقدار حساسیت و مشکل هالو مشکل گرادینت

سرعت محاسبه این تابع نسبت به Parameterized ReLU و Leaky ReLU کمتر است


$$\text{hard-swish}(m) = m \frac{\text{ReLU}(m+3)}{6}$$

این یک محاسبه Swish میخوره استفاده از تابع sigmoid

بسیار بیشتر از آن hard-swish است

آدم سوال ۲ حضرت للہ (۱۳) : اِنَّا مَجَادَّةَ اللّٰهِ رَجَعْنَا اِلَیْكَ یَا اَدَمُ
 تَطَهَّرْ تَطَهَّرْ اَمْسَتْ و مِلَّان صَدَّقْ لَیْ وَ دَسْتَا لَیْ وَ اَدَمُ رَجَعْنَا اِلَیْكَ یَا اَدَمُ
 مَن اَمَلَتْ مَزْرُور و سَبَّحْتَ بِاللّٰهِ رَجَعْتَ حَلَر حَکَمْتَ لَیْ لَدِیَّان اَمْسَتْ. اِنَّا اَللّٰهُ رَجَعْنَا مِلَّانِیَا حَزَوِیَا رَجَعْنَا
 مِلَّانِیَا رَجَعْنَا مِلَّانِیَا حَزَوِیَا رَجَعْنَا مِلَّانِیَا حَزَوِیَا رَجَعْنَا مِلَّانِیَا حَزَوِیَا رَجَعْنَا
 لَیْ سَبَّحْتَ اَصْحَابُ مِلَّانِیَا حَزَوِیَا رَجَعْنَا مِلَّانِیَا حَزَوِیَا رَجَعْنَا مِلَّانِیَا حَزَوِیَا رَجَعْنَا

①



Forward

دالة التنشيط

$$\hat{y} = (h_1 x w_{12} + h_2 x w_{22} + 1) \sigma(1) = y$$

$$h_1 = x_1 w_{11} + x_2 w_{21} + 1.0 = 0.7 \sigma(1.0) = 0.7$$

$$h_2 = x_1 w_{12} + x_2 w_{22} + 1 = 0.1 \sigma(1) = 0.1$$

$$f(z) = \sigma(z) \quad f'(z) = \sigma(z)(1 - \sigma(z))$$

$x = 1$
 $x_1 = 0$
 $x_2 = 1$
 $y = 1$

$$J(w) = \sum_{i=1}^m [-y_i \ln h(n_i) - (1 - y_i) \ln (1 - h(n_i))] =$$

Backward

$$\frac{\partial J(w)}{\partial w_{12}} = \frac{\partial J(w)}{\partial f(z)} \times \frac{\partial f(z)}{\partial z} \times \frac{\partial z}{\partial w_{12}} = \left(-\frac{y}{a} + \frac{(1-y)}{1-a} \right) \times \sigma(z) \times (1 - \sigma(z))$$

$$h(n_i) = f(z) = 0.7 \times w_{12} = \left(-\frac{1}{1.7} + \frac{1}{1.7} \right) \times 0.7 \times 0.1 \times 1 = -\frac{0.7}{100} + \frac{1.7}{100} = \frac{1.0}{100}$$

$$\frac{\partial f(z)}{\partial z} = \sigma(z) \times (1 - \sigma(z)) = 0.7 \times 0.1 = 0.07$$

$$\frac{\partial z}{\partial w_{12}} = h_1 x w_{12} + h_2 x w_{22} + 1 = w_{12} = 1$$

$$w_{12} \leftarrow w_{12} - \alpha \frac{\partial J(w)}{\partial w_{12}} = 1 - 0.1 \times \frac{1.0}{100} = 1 - \frac{1.0}{1000} = \frac{999}{1000} \checkmark$$

$$\frac{\partial J(w)}{\partial w_{11}} = \frac{\partial J(w)}{\partial f(z)} \times \frac{\partial f(z)}{\partial z} \times \frac{\partial z}{\partial w_{11}} = \left(-\frac{0.7}{100} + \frac{1.7}{100} \right) \times \frac{1}{7} = -\frac{1}{1000}$$

$$w_{11} \leftarrow w_{11} - \alpha \frac{\partial J(w)}{\partial w_{11}} = \frac{1}{7} - 0.1 \times -\frac{1}{1000} = \frac{1}{7} + \frac{1}{10000} = 0.142901 \checkmark$$


$$\frac{\partial J(w)}{\partial w_1} = \frac{\partial J(w)}{\partial f(z)} \times \frac{\partial f(z)}{\partial z} \times \frac{\partial z}{\partial w_1} \times \frac{\partial z}{\partial h_1} \times \frac{\partial h_1}{\partial w_1} = \left(-\frac{0.7}{100} + \frac{1.7}{100} \right) \times \frac{1}{7} \times \frac{1}{1} \times 0 = 0$$

$$w_1 \leftarrow w_1 - 0 = w_1 \checkmark$$

①

$$y_i = 1$$

$$x = [x_1]$$



دستگاه چهارم حساسیت دارد
ابتدا اشکال گراف را رسم می کنیم.

$$\frac{\partial J}{\partial w_1}$$

$$J = - \sum y_i \log(\hat{y}_i)$$

$$\frac{\partial J}{\partial w_1} = \frac{\partial J}{\partial \text{Softmax}(h_r)} \times \frac{\partial \text{Softmax}(h_r)}{\partial h_r} \times \frac{\partial h_r}{\partial \text{ReLU}(z_r)} \times \frac{\partial \text{ReLU}(z_r)}{\partial z_r}$$

$$\times \frac{\partial z_r}{\partial h_1} \times \frac{\partial h_1}{\partial \text{ReLU}(z_1)} \times \frac{\partial \text{ReLU}(z_1)}{\partial z_1} \times \frac{\partial z_1}{\partial w_1}$$

$$\frac{\partial J}{\partial \text{Softmax}(h_r)} = \text{max} - \frac{y}{y^2} + \frac{1-y}{1-y^2}$$

$$\frac{\partial \text{Softmax}(h_r)}{\partial h_r} = \frac{\partial e^{a_i}}{\sum_{k=1}^N e^{a_k}} = \frac{\partial s_i}{\partial a_j} = s_i (s_{ij} - s_j)$$

$$s_{ij} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases}$$

$$\frac{\partial h_r}{\partial \text{ReLU}(z_r)} = \begin{cases} 1 & z_r > 0 \\ 0 & z_r \leq 0 \end{cases}$$

$$\frac{\partial h_r}{\partial \text{ReLU}(z_r)} = 1, \quad \frac{\partial z_r}{\partial h_1} = w_r, \quad \frac{\partial h_1}{\partial \text{ReLU}(z_1)} = 1, \quad \frac{\partial z_1}{\partial w_1} = x_1$$

$$\frac{\partial J}{\partial w_r} = \frac{\partial J}{\partial \text{Softmax}(h_r)} \times \frac{\partial \text{Softmax}(h_r)}{\partial h_r} \times \frac{\partial h_r}{\partial \text{ReLU}(z_r)} \times \frac{\partial \text{ReLU}(z_r)}{\partial z_r} \times \frac{\partial z_r}{\partial w_r}$$

①

لذا من أجل إيجاد المشتقات:

$$\frac{\partial J}{\partial b_1} = \frac{\partial J}{\partial \text{Softmax}(h_r)} \times \frac{\partial \text{Softmax}(h_r)}{\partial h_r} \times \frac{\partial h_r}{\partial \text{ReLU}(z_r)} \times \frac{\partial \text{ReLU}(z_r)}{\partial z_r}$$

$$\times \frac{\partial z_r}{\partial h_1} \times \frac{\partial h_1}{\partial \text{ReLU}(z_1)} \times \frac{\partial \text{ReLU}(z_1)}{\partial z_1} \times \frac{\partial z_1}{\partial b_1}$$

$$\frac{\partial z_1}{\partial b_1} = 1$$

$$\frac{\partial J}{\partial b_r} = \frac{\partial J}{\partial \text{Softmax}(h_r)} \times \frac{\partial \text{Softmax}(h_r)}{\partial h_r} \times \frac{\partial h_r}{\partial \text{ReLU}(z_r)} \times \frac{\partial \text{ReLU}(z_r)}{\partial z_r} \times \frac{\partial z_r}{\partial b_r}$$

$$\frac{\partial z_r}{\partial b_r} = \frac{\partial J}{\partial b_r} \times \frac{\partial J}{\partial b_r} = \left(\frac{\partial J}{\partial \text{Softmax}(h_r)} \times \frac{\partial \text{Softmax}(h_r)}{\partial h_r} \times \frac{\partial h_r}{\partial \text{ReLU}(z_r)} \times \frac{\partial \text{ReLU}(z_r)}{\partial z_r} \right)$$

$$\times \frac{\partial z_r}{\partial h_1} \times \frac{\partial h_1}{\partial \text{ReLU}(z_1)} \times \frac{\partial \text{ReLU}(z_1)}{\partial z_1} \times \frac{\partial z_1}{\partial b_1} \times \frac{\partial z_r}{\partial b_r}$$

①

$$\frac{\Delta j(\omega)}{\omega_r} = \frac{\Delta j(\omega)}{f(z)} \times \frac{f(z)}{z} \times \frac{z}{h_1} \times \frac{h_1}{\omega_r} = \left(\frac{-r_n}{1000} + \frac{1rf}{100} \right) \times \frac{1f}{1000} \times 1 = 0.001$$

$$\omega_r \approx \omega_r - \frac{1}{1} \times 0.001 = 1 - 0.001 = 0.9999$$

$$\frac{\Delta j(\omega)}{\omega_r} = \frac{\Delta j(\omega)}{f(z)} \times \frac{f(z)}{z} \times \frac{z}{h_r} \times \frac{h_r}{\omega_r} = \left(\frac{-r_n}{1000} + \frac{1rf}{100} \right) \times \frac{1}{r} \times 0.30$$

$$\omega_r \approx \omega_r - 0 = \omega_r$$

$$\frac{\Delta j(\omega)}{\omega_f} = \frac{\Delta j(\omega)}{f(z)} \times \frac{f(z)}{z} \times \frac{z}{h_r} \times \frac{h_r}{\omega_f} = \left(\frac{-r_n}{1000} + \frac{1rf}{100} \right) \times \frac{1}{r} \times \frac{1}{\frac{h_r}{z}} = 0.401$$

$$\omega_f \approx \omega_f - \frac{1}{1} \times 0.401 = -0.401 = -0.401$$